

LANGAGE PYTHON

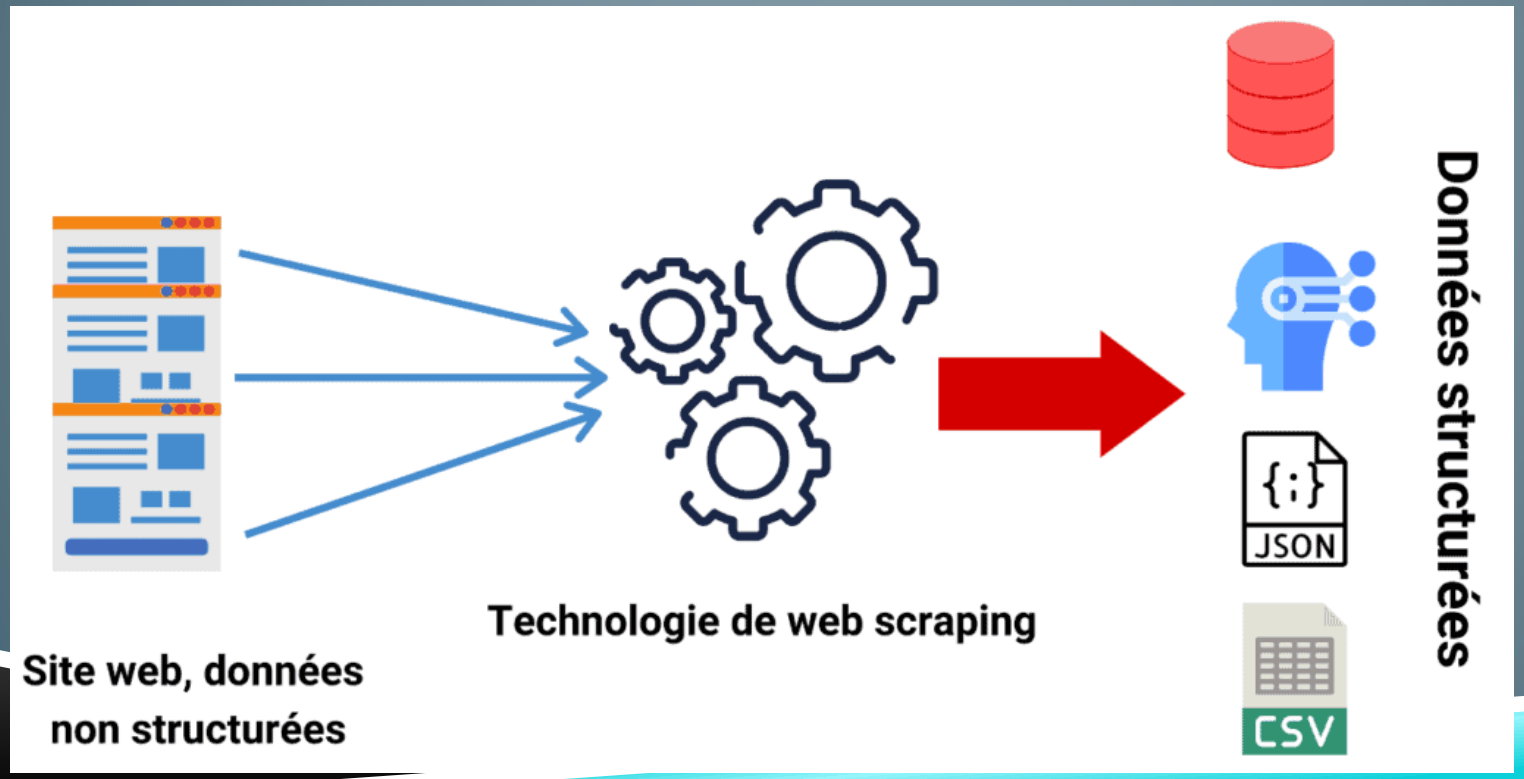
Les données



UNIVERSITÉ CÔTE D'AZUR

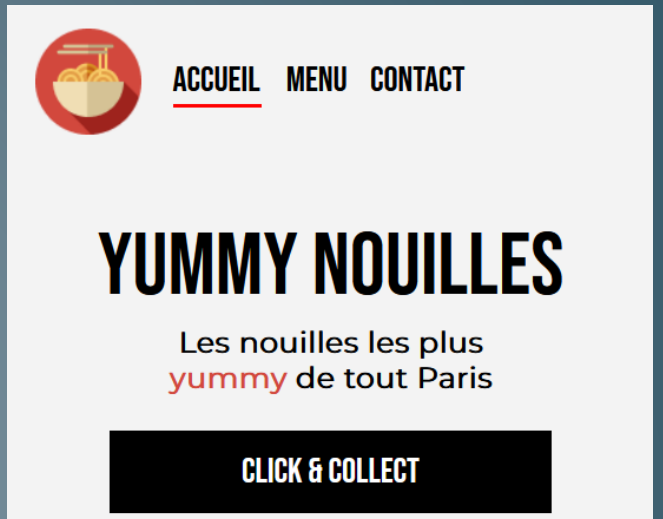
INTRODUCTION AU SCRAPING

- Qu'est-ce que le web scraping ?
  - Méthode automatique qui permet d'obtenir de grandes quantités de données à partir de sites web.



EXEMPLE DE SCRAPING

- Récupération de données du site "Yummy nouilles
  - http://infoweb.unice.fr/site_exemple/



programme scrap.py 3

C: > Users > pperignan > Downloads > env1 > programme scrap.py > ...

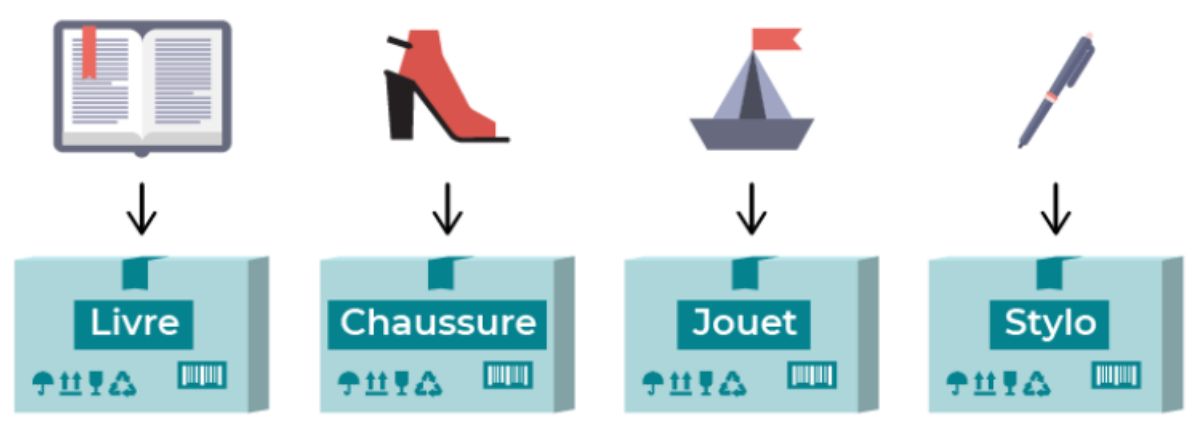
```python
import requests
import bs4
from bs4 import BeautifulSoup as b
url="http://infoweb.unice.fr/site_
resp=requests.get(url)
soup =bs(resp.content, "lxml")
print(soup)
```

Windows PowerShell

```
<!DOCTYPE html>
<html lang="fr">
<head>
<link href="https://fonts.googleapis.com/css?family=Bebas+Neue&amp;display=swap" rel="stylesheet"/>
<link href="https://fonts.googleapis.com/css?family=Montserrat&amp;display=swap" rel="stylesheet"/>
<script crossorigin="anonymous" src="https://kit.fontawesome.com/a1366d1a92.js"></script>
<meta charset="utf-8"/>
<meta content="width=device-width, initial-scale=1.0" name="viewport"/>
<link href="./css/main.css" rel="stylesheet"/>
<title>Document</title>
</head>
<body>
<section class="v1_282">
<img alt="logo" class="v5_660" src="images/logo.png"/>
<a href="#"><span class="v5_661">accueil</span></a>
<a href="#"><span class="v5_662">menu</span></a>
<a href="#"><span class="v5_664">contact</span></a>
<div class="bloc_principal">
<div class="titre">
<h1 class="v1_300">Yummy nouilles</h1>
<h2 class="v1_301">Les nouilles les plus <span>yummy</span> de tout Paris</h2>
<div class="v1_301_a"><p>CLICK &amp; COLLECT</p></div>
</div>
```

LES VARIABLES

- Assimilables à une boite de rangement pour stocker les données



- Une variable est constituée de 3 éléments :

1. Son nom,
2. Son type,
3. Sa valeur,

```
PS C:\Users\pperignan> python
Python 3.12.4 (tags/v3.12.4:8e8a4ba, Jun  6 2024, 19:30:16) [MSC v.1940
Type "help", "copyright", "credits" or "license" for more information.
>>> nom = "DUPONT"
>>> print(nom)
DUPONT
>>> prenom="Paul"
>>> print(f"Bonjour, je me nomme {prenom} {nom}.")
Bonjour, je me nomme Paul DUPONT.
>>>
```

UNIVERSITÉ CÔTE D'AZUR

LES VARIABLES

- Les types de données primitifs sont :
  1. Les entiers (integers),
  2. Les nombres décimaux (floats),
  3. Les chaînes de caractères (string),
  4. Les booléens (True/False),

- Les chaînes de caractères
  - “Bonjour”
  - ‘Au revoir’
  - “C’est un exemple”

Fonction type()

```
PS C:\Users\pperignan> python
Python 3.12.4 (tags/v3.12.4:8e8a4ba, Jun  6 2024, 19:30:16) [MSC v.1940
Type "help", "copyright", "credits" or "license" for more information.
>>> texte="une phrase composée de mots"
>>> nombre=2
>>> booleen=True
>>> type(texte)
<class 'str'>
>>> type(nombre)
<class 'int'>
>>> type(booleen)
<class 'bool'>
```

- Gérer les charactères
  - Utiliser des méthodes : upper(), lower(), find(), etc…

```
>>> texte="une phrase composée de mots"
>>> texte.upper()
'UNE PHRASE COMPOSÉE DE MOTS'
>>> texte.replace("composée", "est constituée")
'une phrase est constituée de mots'
>>>
```

UNIVERSITÉ CÔTE D'AZUR

LES OPÉRATEURS

- On retrouve les 4 opérations arithmétiques
  - Adition => 3 + 4
  - Soustraction => 4 - 3
  - Multiplication => 4 * 2
  - Division => 5 / 2

LES LISTES

- Permettent de stocker une collection de données de différents types :
  - A définir entre […]

```
Python 3.12.4 (tags/v3.12.4:8e8a4ba, Jun  6 2024, 19:30:16)
Type "help", "copyright", "credits" or "license" for more in
>>> fruits=["pomme", "poire", "cerise", "fraise", "banane"]
>>>
```

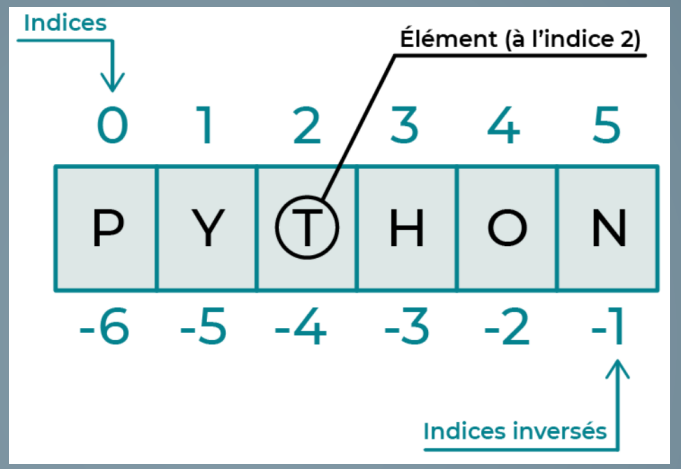
  - Lecture par indice [indice]

```
Python 3.12.4 (tags/v3.12.4:8e8a4ba, Jun  6 2024, 19:30:16)
Type "help", "copyright", "credits" or "license" for more in
>>> fruits=["pomme", "poire", "cerise", "fraise", "banane"]
>>> fruits[0]
'pomme'
>>> fruits[1]
'poire'
>>> fruits[2]
'cerise'
```

LES LISTES

- Accéder aux caractères d'une chaîne avec indice :

```
Python 3.12.4 (tags/v3.12.4:8e8a4ba
Type "help", "copyright", "credits"
>>> chaine="PYTHON"
>>> chaine[2]
'T'
>>> chaine[-4]
'T'
>>>
```



- Gérer les listes
  - Utiliser des méthodes : append(), remove(), len(), sort(), insert(), reverse(), etc…

```
>>> fruits=["pomme", "poire", "cerise", "fraise", "banane"]
>>> fruits.append("citron")
>>> print(fruits)
['pomme', 'poire', 'cerise', 'fraise', 'banane', 'citron']
>>> fruits.remove("cerise")
>>> print(fruits)
['pomme', 'poire', 'fraise', 'banane', 'citron']
>>> fruits.sort()
>>> print(fruits)
['banane', 'citron', 'fraise', 'poire', 'pomme']
```

LES TUPLES

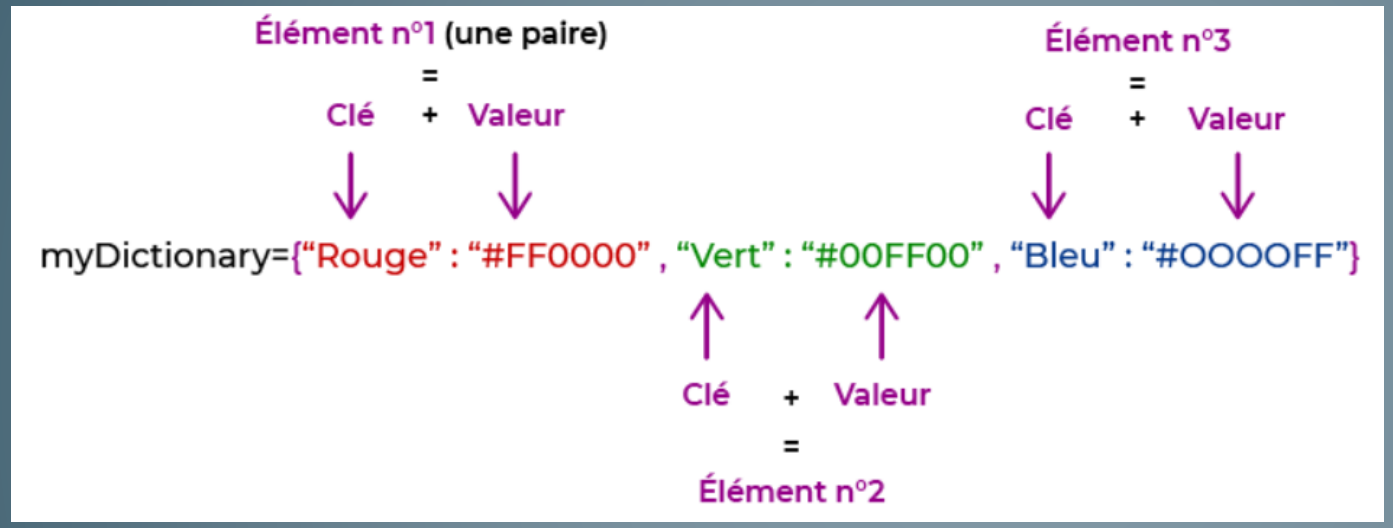
- Permettent également de stocker des données :
  - A définir entre (…)

```
>>> fruits=("pomme", "poire", "cerise", "fraise", "banane")
>>> print(fruits)
('pomme', 'poire', 'cerise', 'fraise', 'banane')
>>>
```

Les tuples sont **immuables**, alors que les listes sont **modifiables**.

LES DICTIONNAIRES

- Permettent stocker des données plus complexes par paire clé/valeur



- A définir entre {…}

```
>>> voiture={"marque":"Ford","modele":"Mustang","annee":"1964"}
>>> print(voiture)
{'marque': 'Ford', 'modele': 'Mustang', 'annee': '1964'}
>>> print(voiture["modele"])
Mustang
>>>
```